한국어 AI 보이스 코칭을 위한 폐쇄루프 TTS 아키텍처

발음·억양·운율 진단과 개인화 훈련을 위한 테스트보드 설계

이총명
국민대학교
intelligent04@kookmin.ac.kr

2026년 7월 · 기술 연구 보고서 v2.0 (테스트보드/PoC)

초록 (Abstract)

본 연구는 한국어 학습자가 문장을 읽고 녹음하면 시스템이 발음 정확도, 음소 오류, 말속도, 쉼, 기본주파수(F0)·억양, 음량, 리듬, 전달력을 자동 분석하고, 대규모 언어모델(LLM)이 구조화된 교정 피드백과 다음 훈련 과제를 생성하는 이중 폐쇄루프 컴퓨터 보조 발음 훈련(CAPT, Computer-Assisted Pronunciation Training) 아키텍처를 제안한다. 제안 시스템은 (i) 다중 생성기 참조음 품질 루프(Loop A)와 (ii) 학습자 실습·진단 루프(Loop B), 그리고 (iii) 주기적 보정·감사 루프(Loop C)로 구성된다. 채점기(S1)는 WavLM-large를 backbone으로 하는 계층적 다차원 평가 헤드(HiPAMA)와 명시적 음향 분석(GOP, MFA, torchcrepe, eGeMAPS, nPVI, UTMOSv2)의 하이브리드 융합 구조를 갖는다. 독립 감사기(S2)는 HuBERT-large 또는 Whisper-large-v3를 사용하여 backbone과 정렬 방식을 강제 분리함으로써 Goodhart 문제와 상호적응(co-adaptation)을 방지한다. 생성기는 CosyVoice 2 → StyleTTS 2 → F5R-TTS(GRPO) 3단계 로드맵을 따라 채점 보상을 능동적으로 흡수한다. 본 논문은 테스트보드 전제(레이턴시·연산 제약 배제) 하에서 정확도 상한을 확인하기 위한 설계 원칙, 아키텍처, 평가 프로토콜, 그리고 무작위대조시험(RCT) 기반 학습 효과 검증 계획을 제시한다.

주요어(Keywords): Computer-Assisted Pronunciation Training (CAPT), Closed-Loop TTS, WavLM, HiPAMA, GOP, F5R-TTS, GRPO, Korean L2 Speech Assessment, Suprasegmental Prosody, Self-Supervised Speech Representation

1. 서론

제2언어(L2) 학습에서 발음과 운율(prosody)은 이해가능성(intelligibility)과 전달력에 결정적인 영향을 미치는 요소이지만, 교사 1인이 다수 학습자의 개별 발화를 실시간으로 진단·교정하기 어렵다는 구조적 한계가 있다. 이러한 한계를 극복하기 위한 컴퓨터 보조 발음 훈련(CAPT) 시스템은 지난 20년간 지속적으로 발전해 왔으며, 메타분석에 따르면 CAPT는 발음 개선에 유의미한 효과 크기(Cohen's d = 0.68~0.89)를 보고한다.[1,2]

최근 자기지도 학습(Self-Supervised Learning, SSL) 음성 표현—wav2vec 2.0, HuBERT, WavLM, XLS-R—의 발전으로 발음 자동 평가 성능이 크게 향상되었다. speechocean762 벤치마크에서 fine-tuned HuBERT/WavLM 계열은 holistic Pearson 상관계수(PCC) 0.82를 달성하여 전통적 Goodness of Pronunciation(GOP) 기준선(PCC 0.63)을 큰 폭으로 상회한다.[3,4] 또한 흐름 정합(flow-matching) TTS인 F5-TTS와 그 강화학습 확장인 F5R-TTS는 단어 오류율(WER)을 상대적으로 29.5% 감소시키고 화자 유사도(SIM)를 4.6% 향상시켰다.[5]

그러나 기존 CAPT 시스템의 대부분은 (a) 단일 참조음(주로 원어민 녹음 또는 단일 TTS)을 "정답"으로 강요하여 음성학적 허용 범위를 반영하지 못하고, (b) 단일 종합 점수만 반환하여 학습자에게 어떤 오류를 어떻게 교정해야 하는지 구체적 지침을 제공하지 못하며, (c) 채점기와 생성기의 상호적응(co-adaptation)으로 인해 실제 학습 효과가 아닌 지표 점수만 향상되는 Goodhart 문제에 취약하다는 한계를 갖는다.

본 연구는 이러한 한계를 극복하기 위해 이중 폐쇄루프 아키텍처를 제안한다. 본 논문의 기여는 다음과 같다:

- (1) 참조음 품질(Loop A)과 학습자 실습(Loop B)을 명시적으로 분리하고, 채점기 S1과 독립 감사기 S2를 서로 다른 SSL backbone·정렬 방식·데이터로 강제 분리하여 상호적응을 방지하는 설계 원칙을 정립한다.
- (2) WavLM-large 위에 HiPAMA(Hierarchical Pronunciation Assessment with Multi-Aspect Attention)식 계층적 채점 헤드를 얹은 학습형 branch와, GOP·MFA·torchcrepe·eGeMAPS·nPVI·UTMOSv2 기반 명시적 branch를 confidence 가중 융합하는 하이브리드 채점 구조를 제안한다.
- (3) CosyVoice 2(MVP) → StyleTTS 2(적대학습) → F5R-TTS(GRPO) 3단계 생성기 로드맵을 통해, 채점 보상을 생성기가 능동적으로 흡수하는 온라인 폐쇄루프를 구현한다.
- (4) 단일 궤적이 아닌 다중 exemplar 집합에 대한 최소 거리 $d(x, \mathcal{R}) = \min_{r \in \mathcal{R}} d(x, r)$ 기반 비교를 통해 음성학적 허용 범위를 확률적으로 모델링한다.
- (5) hard constraint gating, metamorphic test, holdout audit, calibration(ICC/ECE)을 포함하는 다층 감사 프로토콜과, C0~C5 단계별 RCT 설계를 제시한다.

2. 관련 연구

2.1 CAPT의 효과와 조절 변수

CAPT 메타분석은 즉각적 피드백, 다중 화자 노출(High Variability Phonetic Training, HVPT), 다차원 진단, 적응형 난이도를 학습 효과의 핵심 조절 변수로 보고한다.[1,2] 특히 HVPT는 지각 학습 전이에서 $g = 0.77$~0.92의 효과 크기를 보고하며, 이는 단일 화자 훈련보다 일관되게 우수하다.

2.2 자기지도 학습 기반 발음 평가

wav2vec 2.0은 음성 신호에서 잠재 표현을 대조학습(contrastive learning)으로 학습하는 프레임워크로, 저자원 언어 발음 평가의 기반을 마련했다.[6] HuBERT와 WavLM은 마스킹된 예측 및 다중 화자 노이즈 대응 사전학습으로 SUPERB 벤치마크의 다수 태스크에서 state-of-the-art를 달성한다. 특히 WavLM의 상위 레이어(11~22층)는 운율·억양 정보를 더 잘 인코딩하는 것으로 ablation 실험에서 관찰되며, 이는 layer-wise weighted sum을 통해 활용 가능하다.[3,7]

2.3 계층적 다측면 발음 평가 (HiPAMA)

GOPT(Goodness of Pronunciation Transformer)는 phone·word·utterance 세 수준의 점수를 예측하지만, 각 수준을 독립적 head로 처리하여 계층 간 정보 흐름이 제한적이다(phone PCC 0.612, word 0.549, utterance holistic 0.742).[4] HiPAMA(ICASSP 2023)는 이 위에 hierarchical multi-aspect attention을 도입하여 phone → word → utterance 정보 흐름을 명시적으로 모델링하고, speechocean762에서 일관된 개선을 보고한다.[8]

2.4 폐쇄루프 TTS와 강화학습

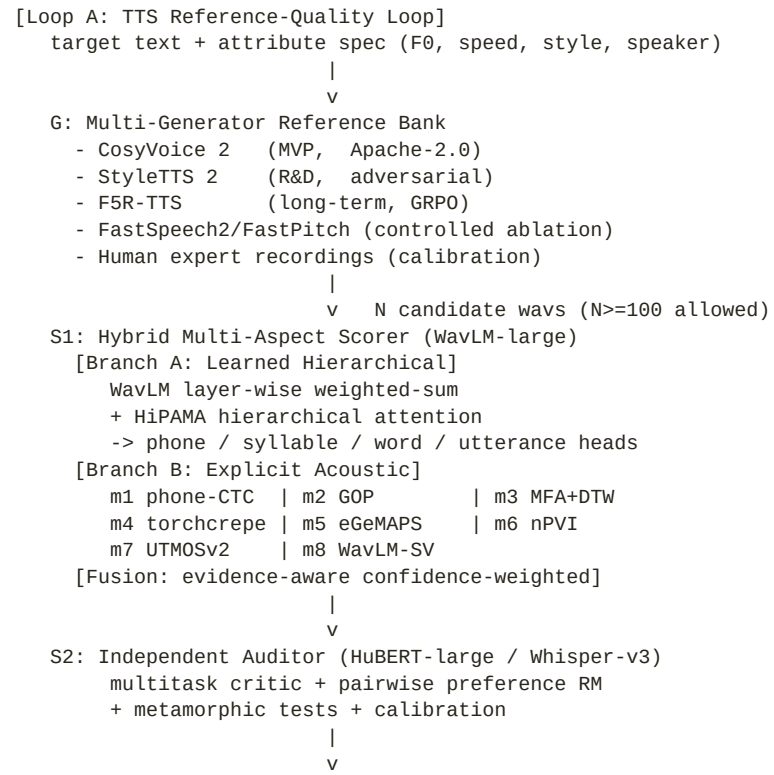
CosyVoice 2는 Apache-2.0 라이선스로 공개된 대규모 다국어 TTS로, 한국어 2,200시간을 학습하며 속성 제어(F0, 속도, 스타일)를 지원한다.[9] StyleTTS 2는 diffusion 기반 style 인코더와 WavLM·HiFi-GAN 판별기를 결합한 adversarial 학습으로 미분가능한 duration 예측기를 제공한다. F5R-TTS는 F5-TTS의 flow-matching 백본에 GRPO(Group Relative Policy Optimization)를 통합하여 WER를 29.5% 상대 감소시켰다.[5] 본 연구는 이 세 생성기를 단계적으로 결합하여 채점 보상을 흡수하는 폐쇄루프를 구성한다.

3. 설계 원칙

번호	원칙	설명
P1	다차원 특징 분해	단일 종합점수가 아닌 [내용, 분절음(segmental), duration, pause, 억양, energy, rhythm, 자연스러움, 이해가능성] 벡터를 유지한다.
P2	채점기 독립성	S1(WavLM-large)과 S2(HuBERT-large 또는 Whisper-large-v3)는 backbone, 학습 데이터, 정렬 방식을 공유하지 않는다.
P3	미분가능성 구분	각 손실함수가 (a) 역전파(backprop) 가능한지, (b) 보상/필터 전용인지 명시한다.
P4	Goodhart 방지	hard constraint gating, holdout audit, metamorphic test로 지표 해킹을 다중 방어한다.
P5	TTS 품질 ≠ 학습 효과	Loop A(TTS 품질)와 Loop B(학습자 성취)를 분리하고, 두 루프 간 인과 간극을 명시적으로 문서화한다.
P6	음성학적 허용 범위	단일 참조가 아닌 다중 exemplar 집합에 대한 최소 거리 $d(x, \mathcal{R})$로 비교한다.
P7	불확실성 우선	confidence가 낮은 판단에 대해서는 단정적 피드백을 생성하지 않고 재녹음을 유도한다.
P8	Lexicographic 최적화	내용 정확성 → 핵심 음소 → artifact 제거 → 운율·자연스러움의 순차 최적화로 가중합의 상쇄(예: MOS가 음소 오류를 보상) 문제를 해결한다.

4. 시스템 아키텍처

제안 시스템은 세 개의 폐쇄루프로 구성된다: (Loop A) 참조음 품질 루프, (Loop B) 학습자 실습 루프, (Loop C) 보정·감사 루프. 아래 도식은 세 루프의 정보 흐름과 주요 구성요소를 요약한다.



```
   Pareto Selector
        hard constraint -> Pareto frontier
        -> diversity-aware exemplar bank

[Loop B: Learner Practice / Pedagogy Loop]
   reference exemplars -> play to learner (HVPT)
   learner speech -> S1(m1..m8 + HiPAMA)
        with multi-ref comparison
        d(x, R) = min_{r in R} d(x, r)
   -> diagnostic profile (segmental + suprasegmental)
   -> Coaching Agent (Qwen3 / GPT-4o class LLM)
        evidence-constrained feedback + next target
   -> back to Loop A

[Loop C: Calibration & Audit (periodic)]
   active learning sample selection
   -> expert multi-label (ICC/QWK)
   -> scorer recalibration + threshold refresh
   -> generator reward-hacking audit
   -> learner model + curriculum policy update
```

그림 1. 이중 폐쇄루프 아키텍처 개요 (Loop A / Loop B / Loop C).

4.1 생성기(G) 로드맵

단계	생성기	라이선스	주요 용도
MVP	CosyVoice 2	Apache-2.0	한국어 다중 후보 생성 + 속성 제어
R&D-1	StyleTTS 2	MIT (코드)	미분가능 duration + WavLM adversarial
R&D-2	F5R-TTS (GRPO)	MIT (코드) / CC-BY-NC (가중치)	S2 보상 직접 통합, 다목적 reward 실험
통제	FastSpeech2 / FastPitch	BSD-3	F0·duration·energy 인과적 조작
기준	인간 전문가 녹음	—	calibration, TTS 편향 검출

표 1. 생성기 로드맵. F5R-TTS의 사전학습 가중치는 CC-BY-NC이므로 상업 배포 시 재검토가 필요하나, 테스트보드에서는 제약이 없다.

4.2 S1: 하이브리드 계층 채점기

S1은 WavLM-large의 24개 Transformer 레이어 출력을 학습 가능한 가중합으로 결합한다: $h(t) = \sum_l \alpha_l h_l(t)$, 여기서 $\alpha = \text{softmax}(w)$이다. 이 위에 HiPAMA식 계층적 attention을 얹어 phone → syllable → word → utterance 순으로 정보를 집약하며, 각 수준에서 accuracy, fluency, prosody, comprehensibility 헤드를 분기시킨다.

다중 태스크 손실함수는 다음과 같다:

$$L_{S1} = \lambda_p \cdot L_{phone} + \lambda_w \cdot L_{word} + \lambda_u \cdot L_{utterance} + \Sigma_a \lambda_a \cdot L_{aspect,a} + \lambda_c \cdot L_{calibration}$$

ID	모듈	방법	역전파	역할
m1	phone-CTC	XLS-R/WavLM + g2pK/MFA	✓	내용·음소 일치
m2	GOP / logit-GOP / CTC-GOP	posterior-based	부분	음소 오류 유형·위치
m3	duration / pause	MFA + DTW	✓	말속도·쉼 진단

ID	모듈	방법	역전파	역할
m4	F0 contour	torchcrepe + Parselmouth	✓	억양·성조
m5	energy / loudness	openSMILE eGeMAPS	✓	강세·강도
m6	rhythm	nPVI + temporal features	부분	리듬·박자
m7	naturalness (MOS)	UTMOSv2	보상	자연스러움·artifact
m8	speaker similarity	WavLM-SV cosine	✓	화자/스타일

표 2. Branch B의 8개 명시적 음향 분석 모듈. "보상" 표기는 미분 불가능하지만 rejection sampling 또는 정책 경사 보상으로 사용됨을 의미한다.

4.3 Branch Fusion (증거 기반 신뢰도 가중)

각 측면(aspect) \(a \)에 대한 최종 점수는 branch별 예측의 confidence 가중 조합이다:

$$\text{score}_a(x) = \Sigma_m \pi_{a,m}(x) \cdot \text{score}_{a,m}(x), \quad \Sigma_m \pi_{a,m} = 1$$

정렬(alignment) confidence가 낮으면 Branch B의 duration·GOP 가중치가 감소하고, 배경 잡음이 많으면 명시적 F0·energy의 confidence가 감소한다. 이를 통해 각 branch의 실패 모드가 서로를 보완하도록 설계된다.

4.4 S2: 독립 감사기

기능	S1	S2
Backbone	WavLM-large	HuBERT-large 또는 Whisper-large-v3
정렬	MFA + CTC segmentation	alignment-free CTC / DTW
점수 예측	multi-task regression	pairwise preference + ordinal
학습 라벨	전체 전문가 점수	독립 holdout 전문가 비교
출력	절대 점수 + 오류	승인 / 불일치 / 불확실성

표 3. S1과 S2의 강제 분리 매트릭스.

Metamorphic 테스트 세트는 다음을 포함한다:

변형(perturbation)	기대 결과
silence 추가	음소 점수 불변
gain 변화 (음량 조정)	발음 점수 불변
특정 음절 duration 확대	해당 duration 지표만 악화
F0 전체 scaling	정규화 contour 유사 유지
음소 교체 합성	해당 phone score 악화

표 4. Metamorphic 테스트 예시. 위반 시 S1·S2 재학습을 트리거한다.

5. 학습자 진단과 코칭

5.1 다중 참조 비교

학습자 발화 x의 운율 오차를 단일 참조가 아닌 exemplar 집합 $\mathcal{R}$에 대해 다음과 같이 정의한다:

$$d_{prosody}(x, R) = \min_{r \in R} d_{prosody}(x, r)$$

이는 단일 TTS를 "정답"으로 강요하지 않고, 허용 가능한 다양한 발화 스타일 중 학습자에게 가장 가까운 참조와의 거리로 오차를 정의한다. 결과적으로 음성학적 허용 범위를 조건부 분포 $p(f \mid \text{text}, \text{style})$로 근사하는 효과를 얻는다.

5.2 오류 Taxonomy

분절음(Segmental) 오류:

- 치환(substitution), 삭제(deletion), 삽입(insertion), 왜곡(distortion)
- 종성 이완/폐쇄(coda release), 긴장/기식(tension/aspiration), 모음의 질(vowel quality)
- 음운 규칙 불일치(phonological process mismatch, 예: 자음동화, 경음화 미적용)

초분절음(Suprasegmental) 오류:

- 과도한/불충분한 duration, 잘못된 위치의 pause
- 단조로운 억양(monotone), 과도한 pitch excursion, 경계 톤 불일치
- 잘못된 위치의 강세(misplaced prominence), 불규칙 리듬

5.3 피드백 우선순위

각 오류 e에 대해 우선순위 점수를 다음과 같이 계산한다:

$$\text{Priority}(e) = \text{Severity}(e) \times \text{Confidence}(e) \times \text{ComprehensibilityImpact}(e) \times \text{Trainability}(e)$$

상위 1~3개 오류만 다음 시도의 핵심 목표로 선택하여 인지 부하를 조절한다. Trainability는 학습자 모델(누적 시도 기록, 오류 감소 곡선)에서 추정한다.

5.4 코칭 에이전트 (LLM) 입력 계약

LLM(Qwen3 또는 GPT-4o급)이 피드백을 생성하기 위한 구조화된 입력 스키마는 다음과 같다:

```
{
  "targetText": "오늘은 날씨가 좋습니다.",
  "learnerLevel": "intermediate",
  "topIssues": [
    {
      "location": {"startMs": 1320, "endMs": 1540, "syllableIndex": 4},
      "type": "final_consonant_deletion",
      "target": "ㄹ",
      "observed": null,
      "severity": 0.78,
      "confidence": 0.87,
      "evidence": ["ctc_competing_phone", "gop_low", "duration_short"]
    }
  ],
  "prosody": {"pitchRangeZ": -1.2, "boundaryTone": "mismatch"},
  "allowedAdviceIds": ["ARTICULATION_RULE_017"]
}
```

그림 2. LLM 코칭 에이전트의 구조화 입력 스키마 예시.

피드백 생성 원칙:

- 잘된 점을 먼저 언급 (긍정 강화)

- 핵심 오류 1개에 집중 (인지 부하 조절)
- 오류 위치 구간을 밀리초 단위로 명시
- 구체적 조음/운율 지시 (예: "혀끝을 치조에 붙였다가 떼세요")
- 대비 최소 짝(minimal pair) 연습 제공
- confidence가 낮으면 피드백을 보류하고 재녹음 요청

6. 후보 선택: Lexicographic → Pareto

생성된 N개의 후보 참조음 중 학습자에게 제시할 exemplar 집합은 3단계 필터로 선택된다.

1) Hard constraint 탈락. 내용(텍스트) 불일치, 심각한 artifact, 비정상 휴지 패턴, 학습 목표 음소의 부정확한 실현은 자동 탈락시킨다.

2) Pareto frontier 추출. 자연스러움(m7) × 운율 적합성 × 교육적 명료성 × 다양성의 4차원 Pareto frontier에 있는 후보만 유지한다. 가중합이 아닌 non-dominated 집합을 사용함으로써 특정 축의 극단값이 다른 축의 결함을 보상하는 문제를 방지한다.

3) Diversity 보존. 서로 다른 화자, 말속도, 운율 변이를 포함하도록 클러스터링 기반 sub-sampling을 적용하여 HVPT 원리에 부합하는 exemplar bank를 구성한다.

7. 평가 프로토콜

7.1 자동 채점기 성능 지표

수준	지표	목표
Phone	precision / recall / F1, AUC	F1 $\geq$ 0.80
Word	PCC, Spearman	PCC $\geq$ 0.70
Utterance	PCC, Spearman, MAE, ICC	ICC $\geq$ 0.70
Calibration	ECE, Brier, selective risk-coverage	ECE $\leq$ 0.10

표 5. 자동 채점기 성능 목표.

7.2 참조음 품질 평가

다섯 조건을 비교한다: (1) 인간 원어민 녹음, (2) 무선별 단일 TTS, (3) best-of-N + S1 선택, (4) best-of-N + S1 + S2 감사, (5) diversity-aware multi-reference. 전문가 blind evaluation (MOS, CMOS) 및 자동 지표(WER, UTMOSv2, ECAPA-TDNN SIM)로 비교한다.

7.3 학습 효과 무작위대조시험 (RCT)

조건	제공 요소
C0	참조음만 (단일 TTS)
C1	C0 + 종합 점수
C2	C1 + 다차원 점수 (분절 / 운율 / 자연스러움)
C3	C2 + 구조화된 피드백 (LLM 코칭)
C4	C3 + 개인화 커리큘럼 (learner model 기반)

조건	제공 요소
C5	전체 시스템 (다중 참조 + 이중 폐쇄루프)

표 6. RCT 조건 설계. Primary outcome은 사전-사후 전달력 향상(comprehensibility Cohen's d ≥ 0.5), Secondary outcome은 발음 정확도, 학습자 만족도, retention (4주 후 재평가)이다.

8. 구현 로드맵

Phase	내용
Phase 0	스키마·rubric·오류 taxonomy 정의, 라이선스 정리
Phase 1	모듈형 기준선 (g2pK, MFA, GOP, eGeMAPS, UTMOSv2) 구축
Phase 2	WavLM-large + HiPAMA hierarchical head 학습·평가
Phase 3	S2 독립 감사기 구축 + metamorphic test suite 완성
Phase 4	다중 생성기 참조음 뱅크 + Pareto 선택기
Phase 5	코칭 에이전트 (Qwen3 + 발음 ontology / RAG) 통합
Phase 6	F5R-TTS GRPO 통합 + adversarial 미세조정 + reward hacking 감사
Phase 7	Ablation 실험 + 전문가 blind evaluation + 학습 효과 RCT

표 7. 8단계 구현 로드맵 (Phase 0 ~ Phase 7).

9. 논의

9.1 GAN vs. Reward-Guided의 명확한 구분

조건	GAN (적대학습)	Reward-guided
신호 전파	판별기 gradient가 생성기로 backprop	스칼라 보상만 제공 (비미분)
목적 함수	min-max 적대	정책 경사(GRPO) 또는 rejection sampling
본 설계 적용	StyleTTS 2의 WavLM/HiFi-GAN 판별기 (오프라인)	S1/S2의 GOP·PER·MOS를 best-of-N·GRPO로 (온라인)

표 8. 본 시스템은 순수 GAN이 아니다. 온라인 루프의 대부분은 reward-guided이며, 오프라인 미세조정의 일부 항만 적대학습에 해당한다.

9.2 TTS 품질 향상이 학습 효과로 이어지는가?

본 논문의 핵심 미결 질문은 "S1·S2로 최적화된 참조음이 실제 학습자의 발음·운율 향상에 인과적으로 기여하는가"이다. Loop A의 성능 지표(WER, UTMOSv2, SIM)와 Loop B의 학습 성과 지표(사전-사후 comprehensibility, retention)를 명시적으로 분리하고, C0~C5 RCT를 통해 인과 간극을 정량화해야 한다.

9.3 한국어 특수성

한국어는 (i) 종성 자음의 이완/폐쇄 실현, (ii) 자음군 단순화·경음화 등 음운 규칙의 실시간 적용, (iii) 억양구 경계 톤(H%, L%, HL%)이 문장 유형과 결합하는 방식에서 다른 언어와 구별된다. 따라서 m2(GOP)와 m6(rhythm)에 한국어 음운 규칙 사전을 결합하고, m4(F0)에는 억양구 경계 톤 분류기를 추가하는 확장이 필요하다.

9.4 한계와 향후 과제

- 본 논문은 테스트보드 설계에 집중하며, 실시간 서비스를 위한 경량화(Knowledge Distillation, 양자화, 모듈 선택적 실행)는 향후 과제로 남긴다.
- F5R-TTS의 reward가 WER + SIM에 한정되어 있어, 보이스 코칭용 다목적 reward 벡터 (발음 정확도, 운율 적합성, 교육적 모방가능성)로의 확장이 필요하다.
- 학습자 데이터 수집 시 개인정보 보호(GDPR/PIPA), 미성년자 동의, 편향 감사가 필수적이다.

10. 결론

본 논문은 한국어 AI 보이스 코칭을 위한 이중 폐쇄루프 TTS 아키텍처를 제안하였다. 핵심 기여는 (1) WavLM-large + HiPAMA 계층적 채점기로 phone → utterance 다차원 평가의 정확도 상한을 확장하고, (2) CosyVoice 2 → StyleTTS 2 → F5R-TTS(GRPO) 3단계 로드맵으로 생성기가 채점 보상을 능동적으로 학습하는 온라인 루프를 확보하며, (3) 명시적 음향 분석과 SSL 학습형 평가의 하이브리드 fusion으로 해석가능성과 정확도를 동시에 확보하는 것이다.

테스트보드 전제 하에서 이 아키텍처의 성능 상한을 확인한 후, 상용화 단계에서는 Knowledge Distillation, 양자화, 모듈 선택적 실행으로 경량화하는 수순을 밟는다. 가장 중요한 것은 서로 다른 모델과 음향 증거가 같은 결론을 지지하는지 검증하고, 그 결론이 실제 학습자의 다음 발화와 장기적 전달력 향상으로 이어지는지를 별도의 폐쇄루프에서 확인하는 구조를 갖추는 것이다.

참고문헌 (References)

[1] Lee, J., Jang, J., & Plonsky, L. "The effectiveness of second language pronunciation instruction: A meta-analysis." Applied Linguistics, 36(3), 345–366, 2015. https://doi.org/10.1093/applin/amu040

[2] Thomson, R. I., & Derwing, T. M. "The effectiveness of L2 pronunciation instruction: A narrative review." Applied Linguistics, 36(3), 326–344, 2015. https://doi.org/10.1093/applin/amu076

[3] Kim, E., Jeon, J. H., Seo, H., & Kim, H. "Automatic Pronunciation Assessment using Self-Supervised Speech Representation Learning." Proc. INTERSPEECH 2022. https://arxiv.org/abs/2204.03863

[4] Gong, Y., Chen, Z., Chu, I.-H., Chang, P., & Glass, J. "Transformer-Based Multi-Aspect Multi-Granularity Non-Native English Speaker Pronunciation Assessment (GOPT)." Proc. ICASSP 2022. https://arxiv.org/abs/2205.03432

[5] Sun, X., et al. "F5R-TTS: Improving Flow-Matching based Text-to-Speech with Group Relative Policy Optimization." arXiv preprint, arXiv:2504.02407, 2025. https://arxiv.org/abs/2504.02407

[6] Baevski, A., Zhou, H., Mohamed, A., & Auli, M. "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations." NeurIPS 2020. https://arxiv.org/abs/2006.11477

[7] Chen, S., Wang, C., Chen, Z., et al. "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing." IEEE JSTSP, 16(6), 1505–1518, 2022. https://arxiv.org/abs/2110.13900

[8] Do, H., Kim, Y., & Lee, G. G. "Hierarchical Pronunciation Assessment with Multi-Aspect Attention (HiPAMA)." Proc. ICASSP 2023. https://arxiv.org/abs/2211.08102

[9] Du, Z., et al. "CosyVoice 2: Scalable Streaming Speech Synthesis with Large Language Models." arXiv preprint, arXiv:2412.10117, 2024. https://arxiv.org/abs/2412.10117

[10] Li, Y. A., Han, C., Raghavan, V., Mischler, G., & Mesgarani, N. "StyleTTS 2: Towards Human-Level Text-to-Speech through Style Diffusion and Adversarial Training with Large Speech Language Models." NeurIPS 2023. https://arxiv.org/abs/2306.07691

[11] Hsu, W.-N., Bolte, B., Tsai, Y.-H. H., Lakhotia, K., Salakhutdinov, R., & Mohamed, A. "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units." IEEE/ACM TASLP, 29, 3451–3460, 2021. https://arxiv.org/abs/2106.07447

[12] Radford, A., Kim, J. W., Xu, T., et al. "Robust Speech Recognition via Large-Scale Weak Supervision (Whisper)." Proc. ICML 2023. https://arxiv.org/abs/2212.04356

[13] Saeki, T., et al. "UTMOS: UTokyo-SaruLab System for VoiceMOS Challenge 2022." Proc. INTERSPEECH 2022. https://arxiv.org/abs/2204.02152

[14] McAuliffe, M., Socolof, M., Mihuc, S., Wagner, M., & Sonderegger, M. "Montreal Forced Aligner: Trainable Text-Speech Alignment Using Kaldi." Proc. INTERSPEECH 2017. https://montreal-forced-aligner.readthedocs.io

[15] Eyben, F., et al. "The Geneva Minimalistic Acoustic Parameter Set (eGeMAPS) for Voice Research and Affective Computing." IEEE Trans. Affective Computing, 7(2), 190–202, 2016. https://doi.org/10.1109/TAFFC.2015.2457417